

# 寻找潜在的蜂蜜市场

10225501464 施长林

## DaSE 导论结课项目

- 1 项目介绍
- 安徽岳西盛产高品质的天然蜂蜜，然而当地农民确苦于没有销售渠道，为了帮助农民销售，在调研了中国蜂蜜市场情况后，欲使用数据科学的方法，探究哪个省份可能存在潜在的未发掘的蜂蜜市场。
- 2 数据获取
- 本项目中，主要采用了爬虫的方法获取数据，数据主要来自于国家数据网站的分省数据部分<https://data.stats.gov.cn/easyquery.htm?cn=E0103>，对其中一些可能相关的指标的各省份近十年数据进行了爬取。

- 2.1 请求网页
- 国家数据网站基于XHR，使用开发者模式研究Fetch/XHR，例如点击指标-人口-总人口,有如下信息：

名称	×	标头	载荷	预览	响应	启动器	时间	Cookie
easyquery.htm			▼查询字符串参数	查看源代码	查看网址编码格式的数据			
easyquery.htm?m=getOtherWds...			m: QueryData					
easyquery.htm?m=QueryData&d...			dbcode: fsnd					
easyquery.htm?m=QueryData&d...			rowcode: zb					
			colcode: sj					
			wds: [{"wdcode": "reg", "valuecode": "110000"}]					
			dfwds: [{"wdcode": "zb", "valuecode": "A0301"}]					
			k1: 1705730169518					
			h: 1					

再点击最近十年，有如下变化：

名称	×	标头	载荷	预览	响应	启动器	时间	Cookie
easyquery.htm			▼查询字符串参数	查看源代码	查看网址编码格式的数据			
easyquery.htm?m=getOtherWds...			m: QueryData					
easyquery.htm?m=QueryData&d...			dbcode: fsnd					
easyquery.htm?m=QueryData&d...			rowcode: zb					
easyquery.htm?m=QueryData&d...			colcode: sj					
			wds: [{"wdcode": "reg", "valuecode": "110000"}]					
			dfwds: [{"wdcode": "sj", "valuecode": "LAST10"}]					
			k1: 1705730199587					

即dfwds有两组，分别是指标代码和时间范围，而省份的选择则会影响wds中的

*valuecode*, *k1*是时间戳。通过*requests*库发送这些信息进行爬虫。

## 2.2 内容解析

解析上一步中保存至本地的网页*JSON*文件,

```
[{"returncode": 200,
  "returndata": {
    "datanodes": [
      {
        "code": "zb.A020101_reg.110000_sj.2023",
        "data": {
          "data": 0.0,
          "dotcount": 1,
          "hasdata": false,
          "strdata": ""
        },
        "wds": [
          {
            "valuecode": "A020101",
            "wdcode": "zb"
          },
          {
            "valuecode": "110000",
            "wdcode": "reg"
          },
          {
            "valuecode": "2023",
            "wdcode": "sj"
          }
        ]
      },
      {
        "code": "zb.A020101_reg.110000_sj.2022",
        "data": {
          "data": 41610.9,
          "dotcount": 1,
          "hasdata": true,
          "strdata": "41610.9"
        },
        "wds": [
          {
            "valuecode": "A020101",
            "wdcode": "zb"
          },
          {
            "valuecode": "110000",
            "wdcode": "reg"
          },
          {
            "valuecode": "2022",
            "wdcode": "sj"
          }
        ]
      }
    ]
  }
},
]
```

可以看到实际的数据位于*strdata*中。此处注意到，网站目前更新了2023的条目，但没有数据，所以爬取出来的都有一个空的2023项目，为了获得2022 – 2013十年中的数据，我们需要请求*LAST11*，然后去除掉2023的条目。根据此*JSON*

的格式，可以用 ["returndata"]["datanodes"][i]["data"]["strdata"] 来提取 *strdata*，*i* 是节点的序号，类似于二维数组在内存中的排布，由列数（年份）和行数（指标）确定一个数据所在节点的序号。

2.3 数据存储

采取的策略是将每一个指标保存为一个 *csv* 文件，它的每一列代表一个年份，从 2022 年到 2013 年；而每一行则代表一个省份，按省份代码排序。

2.4 数据处理

在进一步分析前需要处理爬取得到的数据中的空缺，此处采用线性插值的方法来填充缺失的数据；还需要对数据进行归一化，对某指标的某一年数据，有

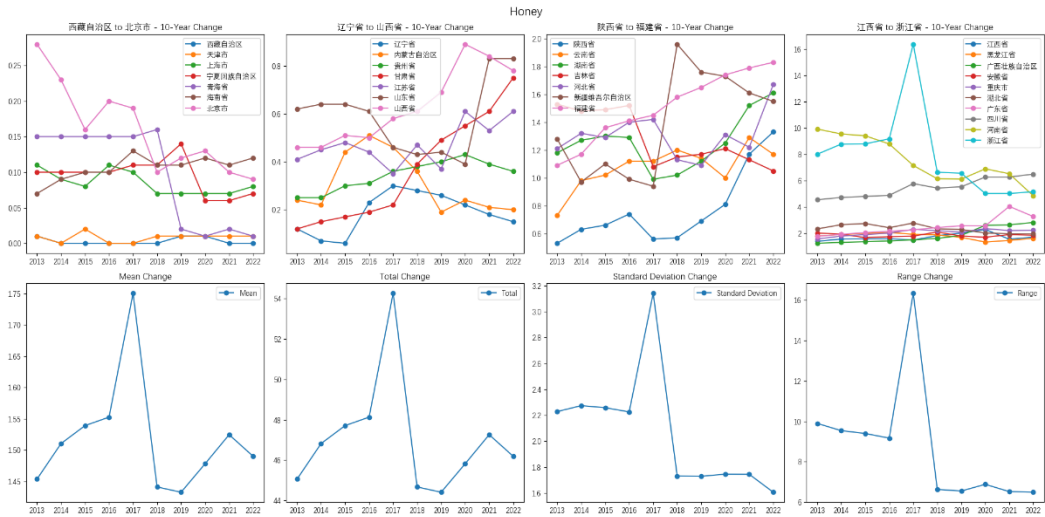
$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

2.5 补充数据

利用直接爬取得到的数据，可以计算衍生指标。例如，由城市人口和总人口数，可以计算出城市人口率作为一项新的指标。除了从国家数据网站上爬取的这些指标的数据，另从行业报告中收集了个省份蜂蜜表现需求量的数据，以同样的格式用 *csv* 文件存储。

3 基本统计信息与可视化

对于采集到的各项指标，各城市的十年变化，我们分析一些基本的统计指标，例如均值，总数，标准差和极差，进行可视化展示，例如蜂蜜产量：




各种指标的图标位于 `./plot/index_change`


4 特征工程

4.1 相关性分析

各指标的相关系数如下：



随机森林模型得出的特征重用性如下：




综合两者考虑，可以选择下列特征用于建模

"Life\_Expectancy\_M",  
 "SLE",  
 "Population",  
 "GDP",


"Honey"

#### 4.2 PCA降维

除了直接选取可能相关的特征，还可以用PCA对数据进行降维，如下图所示：




尝试将数据由PCA降至二维：




#### 5 数据建模

尝试使用线性回归模型进行建模，用2013 – 2021的数据训练模型，评估模型效果。


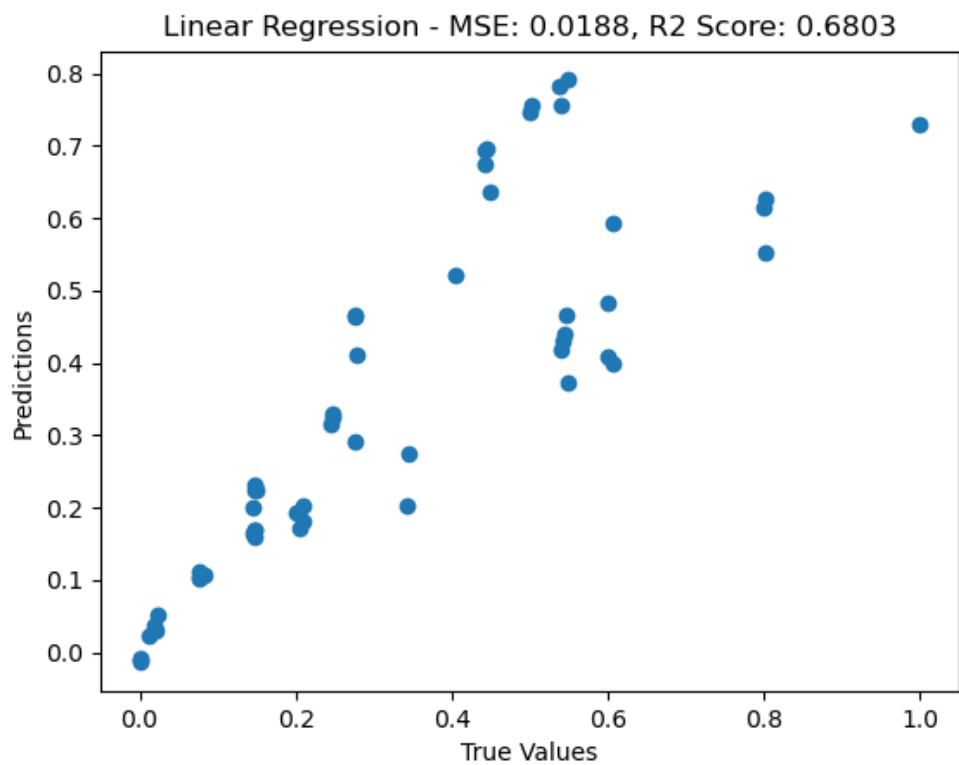
例如，用4.1中分析出的5个可能比较重要的特征建模：



通过 $MSE$ 和 $R^2$ 可知，模型效果尚可，用模型对2022年的数据进行预测，再与2022年的实际值比较，以预测值减去实际值为差异，如果较大，说明该省份可能有潜在的蜂蜜市场，如下图所示：



还可以用4.2中获得的 $PCA$ 降维后的数据进行回归分析，类似可得：



## 6 总结

### 6.1 初步结论

根据以上两种方法处理后的数据的回归结果可知，有几个省份有比较明显的实际值小于预测值，包括江苏省，安徽省，山东省，河南省。这些省份作为经济，人口大省，目前可能仍有一定的蜂蜜市场余量没有被发掘，可以加入蜂蜜销售

地点的备选范围中。

## 6.2 反思与展望

本项目中还有诸多不足之处，主要包括采集的指标项目不够多，以及建模比较简单，效果可能不够理想等。未来将在这两个方面继续深化，用更多的数据，更精密的模型进行更精准的预测。